

# Solution for Time Series Analysis (Hamilton, 1994)

Lucca Simeoni Pavan \*

28 de novembro de 2016

---

\*Doutorando em Desenvolvimento Econômico, PPDGE/UFPR - warrenjax@gmail.com

## Capítulo 3

# Processos ARMA estacionários

3.1

$$E(Y_t) = 0 \therefore \mu = 0$$

$$\begin{aligned} \text{Var}(Y_t) &= E(Y_t - \mu)^2 = E(Y_t)^2 = \text{Var}(\varepsilon_t + 2.4\varepsilon_{t-1} + 0.8\varepsilon_{t-2}) \\ &= (1 + 5.76 + 0.64)\sigma^2 = 7.4 \end{aligned}$$

Como a média e a variância não dependem do tempo, o processo é estacionário em covariância.

$$\begin{aligned} \text{Cov}(Y_t, Y_{t-1}) &= E(Y_t - \mu)(Y_{t-1} - \mu) = E(\varepsilon_t + 2.4\varepsilon_{t-1} + 0.8\varepsilon_{t-2})(\varepsilon_{t-1} + 2.4\varepsilon_{t-2} + 0.8\varepsilon_{t-3}) \\ &= (2.4 + 1.92)\sigma^2 = 4.32 \end{aligned}$$

$$\begin{aligned} \text{Cov}(Y_t, Y_{t-2}) &= E(Y_t - \mu)(Y_{t-2} - \mu) = E(\varepsilon_t + 2.4\varepsilon_{t-1} + 0.8\varepsilon_{t-2})(\varepsilon_{t-2} + 2.4\varepsilon_{t-3} + 0.8\varepsilon_{t-4}) \\ &= 0.8E(\varepsilon_{t-2}^2) = 0.8\sigma^2 = 0.8 \end{aligned}$$

3.2

$$\begin{aligned} Y_t &= 1.1Y_{t-1} - 0.18Y_{t-2} + \varepsilon_t \\ (1 - 1.1L + 0.18L^2)Y_t &= \varepsilon_t \\ Y_t &= (1 - 1.1L + 0.18L^2)^{-1}\varepsilon_t \end{aligned}$$

$$E(Y_t) = (1 - 1.1L + 0.18L^2)^{-1}E(\varepsilon_t) = 0 \therefore \mu = 0$$

Encontrando a variância :  $\gamma_0$

$$\begin{aligned} Y_t^2 &= 1.1Y_tY_{t-1} - 0.18Y_tY_{t-2} + Y_t\varepsilon_t \\ E(Y_t^2) &= 1.1E(Y_tY_{t-1}) - 0.18E(Y_tY_{t-2}) + E(Y_t\varepsilon_t) \\ \gamma_0 &= 1.1\gamma_1 - 0.18\gamma_2 + \sigma^2 \end{aligned}$$

Encontrando a autocovariância  $\gamma_j$  :

$$\begin{aligned} Y_tY_{t-j} &= 1.1Y_{t-1}Y_{t-j} - 0.18Y_{t-2}Y_{t-j} + Y_{t-j}\varepsilon_t \\ E(Y_tY_{t-j}) &= 1.1E(Y_{t-1}Y_{t-j}) - 0.18E(Y_{t-2}Y_{t-j}) + E(Y_{t-j}\varepsilon_t) \\ \gamma_j &= 1.1\gamma_{j-1} - 0.18\gamma_{j-2} \end{aligned}$$

Dado que  $\rho_j = \gamma_j/\gamma_0$  dividindo ambos os lados de  $\gamma_j$  por  $\gamma_0$  temos:

$$\rho_j = 1.1\rho_{j-1} - 0.18\rho_{j-2}$$

Para  $j = 1$ ,  $\rho_1 = 1.1\rho_0 - 0.18\rho_0$ , então:

$$\rho_1 = \frac{1.1}{(1 + 0.18)} = 0.9322$$

Para  $j = 2$ ,  $\rho_2 = 1.1\rho_1 - 0.18$ , então:

$$\begin{aligned}\rho_2 &= 1.1(0.9322) - 0.18 \\ &= 0.8454\end{aligned}$$

Como  $\gamma_j = \rho_j\gamma_0$ , podemos escrever a variância  $\gamma_0$  como:

$$\begin{aligned}\gamma_0 &= 1.1\rho_1\gamma_0 - 0.18\rho_2\gamma_0 + \sigma^2 \\ &= 1.1(0.9322)\gamma_0 - 0.18(0.8454)\gamma_0 + \sigma^2 \\ &= 1.02542\gamma_0 - 0.152176\gamma_0 + \sigma^2 \\ (1 - 1.02542 + 0.152176)\gamma_0 &= \sigma^2 \\ \gamma_0 &= \frac{\sigma^2}{(1 - 1.02542 + 0.152176)} \approx 7.9\sigma^2\end{aligned}$$

Podemos verificar pela fórmula geral:

$$\gamma_0 = \frac{(1 - \phi_2)\sigma^2}{(1 + \phi_2)[(1 - \phi_2^2)^2 - \phi_1^2]}$$

Dado que  $\phi_1 = 1.1$  e  $\phi_2 = -0.18$

$$\begin{aligned}\gamma_0 &= \frac{(1 + 0.18)\sigma^2}{(1 - 0.18)[(1 + 0.18)^2 - 1.1^2]} \\ &= \frac{(1.18)\sigma^2}{(0.82)[0.182]} \approx 7.9\end{aligned}$$

Como a média e a variância não dependem do tempo, o processo  $\{Y_t\}$  é estacionário em covariância.

Para encontra as autocovariâncias usamos  $\gamma_j = \rho_j\gamma_0$ :

$$\gamma_1 = \rho_1\gamma_0 = 0.9322 \times 7.9\sigma^2 \approx 7.364$$

$$\gamma_2 = \rho_2\gamma_0 = 0.8454 \times 7.9\sigma^2 \approx 6.75$$

3.3

$$\begin{aligned}\psi_0 + \psi_1 L + \psi_2 L^2 + \dots - \phi_1 \psi_0 L - \phi_1 \psi_1 L^2 - \phi_1 \psi_2 L^3 - \dots - \phi_2 \psi_0 L^2 - \phi_2 \psi_1 L^3 - \phi_2 \psi_2 L^4 - \dots \\ - \phi_p \psi_0 L^p - \phi_p \psi_1 L^{p+1} - \phi_p \psi_2 L^{p+2} - \dots = 1\end{aligned}$$

$$\begin{aligned}\psi_0 + [\psi_1 - \phi_1 \psi_0]L + [\psi_2 - \phi_1 \psi_1 - \phi_2 \psi_0]L^2 + [\psi_3 - \phi_1 \psi_2 - \phi_2 \psi_1 - \phi_3 \psi_0]L^3 \\ + [\psi_4 - \phi_1 \psi_3 - \phi_2 \psi_2 - \phi_3 \psi_1 - \phi_4 \psi_0]L^4 + \dots + [\psi_j - \phi_1 \psi_{j-1} - \phi_2 \psi_{j-2} - \dots - \phi_{p-1} \psi_1 - \phi_p \psi_0]L^p = 1\end{aligned}$$

Para  $j = p, p + 1, \dots$

Com isso temos o seguinte sistema de equações:

$$\begin{aligned}\psi_0 &= 1 \\ \psi_1 - \phi_1\psi_0 &= 0 \\ \psi_2 - \phi_1\psi_1 - \phi_2\psi_0 &= 0 \\ \psi_3 - \phi_1\psi_2 - \phi_2\psi_1 - \phi_3\psi_0 &= 0 \\ \psi_4 - \phi_1\psi_3 - \phi_2\psi_2 - \phi_3\psi_1 - \phi_4\psi_0 &= 0 \\ &\vdots \\ \psi_j - \phi_1\psi_{j-1} - \phi_2\psi_{j-2} - \dots - \phi_{p-1}\psi_1 - \phi_p\psi_0 &= 0\end{aligned}$$

Resolvendo a partir de  $\psi_0$ :

$$\begin{aligned}\psi_0 &= 1 \\ \psi_1 - \phi_1\psi_0 &= 0 \Rightarrow \psi_1 = \phi_1 \\ \psi_2 - \phi_1\psi_1 - \phi_2\psi_0 &= 0 \Rightarrow \psi_2 = \phi_1^2 + \phi_2 \\ \psi_3 - \phi_1\psi_2 - \phi_2\psi_1 - \phi_3\psi_0 &= 0 \Rightarrow \psi_3 = \phi_1\psi_2 + \phi_2\psi_1 + \phi_3\psi_0 \\ &\vdots \\ \psi_j - \phi_1\psi_{j-1} - \phi_2\psi_{j-2} - \dots - \phi_{p-1}\psi_1 - \phi_p\psi_0 &= 0 \Rightarrow \psi_j = \phi_1\psi_{j-1} + \phi_2\psi_{j-2} + \dots + \phi_{p-1}\psi_1 + \phi_p\psi_0\end{aligned}$$

Para  $j = p, p + 1, \dots$

Portanto os valores de  $\psi_j$  são a solução para a equação de diferenças de  $n^{\text{ésima}}$  ordem com valor inicial  $\psi_0 = 1$  e  $\psi_{-1} = \psi_{-2} = \dots = \psi_{-p+1} = 0$ . Então, dos resultados das equações em diferença:

$$\begin{bmatrix} \psi_j \\ \psi_{j-1} \\ \vdots \\ \psi_{-p+1} \end{bmatrix} = \mathbf{F}^j \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

Isto é

$$\psi_j = f_{11}^{(j)}$$

3.4

$$\begin{aligned}\psi(L)c &= \psi_0c + \psi_1Lc + \psi_2L^2c + \psi_3L^3c + \dots = \frac{c}{1 - \phi_1L - \phi_2L^2} \\ \text{como } L^j c &= c \quad \forall j \\ \psi(L)c &\equiv \psi(1)c = \psi_0c + \psi_1c + \psi_2c + \psi_3c + \dots = \frac{c}{1 - \phi_1 - \phi_2}\end{aligned}$$

3.5

$$\sum_{j=0}^{\infty} |\psi_j| < \infty$$

Deixe  $\lambda_1$  e  $\lambda_2$  satisfazerem  $1 - \phi_1L - \phi_2L^2 = (1 - \lambda_1L)(1 - \lambda_2L)$ , note que  $\lambda_1$  e  $\lambda_2$  ambos estão dentro do círculo unitário em um processo  $AR(2)$  estacionário em covariância.

Considere primeiro o caso em que as duas raízes  $\lambda_1$  e  $\lambda_2$  sejam reais e distintas. Dado que  $\psi_j = c_1\lambda_1 + c_2\lambda_2$ , temos:

$$\begin{aligned}\sum_{j=0}^{\infty} |\psi_j| &= \sum_{j=0}^{\infty} |c_1\lambda_1^j + c_2\lambda_2^j| \\ &< \sum_{j=0}^{\infty} |c_1\lambda_1^j| + |c_2\lambda_2^j| \\ &= \frac{|c_1|}{(1 - |\lambda_1|)} + \frac{|c_2|}{(1 - |\lambda_2|)} \\ &< \infty\end{aligned}$$

Considere o caso em que  $\lambda_1$  e  $\lambda_2$  sejam raízes complexas conjugadas distintas. Deixe  $R = |\lambda_i|$  representar o modulo de  $\lambda_1$  ou  $\lambda_2$ . Então  $0 \leq R < 1$ . Dado que no caso de raízes complexas conjugadas distintas,

$$c_1\lambda_1^j + c_2\lambda_2^j = 2\alpha R^j \cos(\theta j) + 2\beta R^j \sin(\theta j).$$

$$\begin{aligned}\sum_{j=0}^{\infty} |\psi_j| &= \sum_{j=0}^{\infty} |c_1\lambda_1^j + c_2\lambda_2^j| \\ &= \sum_{j=0}^{\infty} |2\alpha R^j \cos(\theta j) + 2\beta R^j \sin(\theta j)| \\ &\leq |2\alpha| \sum_{j=0}^{\infty} R^j |\cos(\theta j)| + |2\beta| \sum_{j=0}^{\infty} R^j |\sin(\theta j)| \\ &\leq |2\alpha| \sum_{j=0}^{\infty} |R^j| + |2\beta| \sum_{j=0}^{\infty} |R^j| \\ &= 2 \frac{(|\alpha| + |\beta|)}{(1 - R)}\end{aligned}$$

Por fim, para o caso de raízes reais repetidas  $|\lambda| < 1$ ,

$$\sum_{j=0}^{\infty} |\psi_j| = \sum_{j=0}^{\infty} |k_1\lambda^j + k_2j\lambda^{j-1}| \leq |k_1| \sum_{j=0}^{\infty} |\lambda^j| + |k_2| \sum_{j=0}^{\infty} |j\lambda^{j-1}|.$$

Mas

$$|k_1| \sum_{j=0}^{\infty} |\lambda^j| = \frac{|k_1|}{(1 - |\lambda|)} < \infty$$

e

$$\begin{aligned}\sum_{j=0}^{\infty} |j\lambda^{j-1}| &= 1 + 2|\lambda| + 3|\lambda|^2 + 4|\lambda|^3 + \dots \\ &= 1 + (|\lambda| + |\lambda|) + (|\lambda|^2 + |\lambda|^2 + |\lambda|^2) \\ &\quad + (|\lambda|^3 + |\lambda|^3 + |\lambda|^3 + |\lambda|^3) + \dots \\ &= (1 + |\lambda| + |\lambda|^2 + |\lambda|^3 + \dots) + (|\lambda| + |\lambda|^2 + |\lambda|^3 + \dots) + (|\lambda|^2 + |\lambda|^3 + \dots) + \dots \\ &= \frac{1}{(1 - |\lambda|)} + \frac{|\lambda|}{(1 - |\lambda|)} + \frac{|\lambda|^2}{(1 - |\lambda|)} + \dots \\ &= \frac{1}{(1 - |\lambda|)} \\ &< \infty\end{aligned}$$

**3.6**  $AR(\infty)$ :

$$(1 + \eta_1 L + \eta_2 L^2 + \dots)(Y_t - \mu) = \varepsilon_t$$

$MA(q)$ :

$$(Y_t - \mu) = (1 + \theta_1 L + \theta_2 L^2 + \dots + \theta_q L^q) \varepsilon_t$$

Dado que as raízes de  $1 + \theta_1 z + \theta_2 z^2 + \dots + \theta_q z^q$  são todas reais e distintas e estão fora do círculo unitário e o processo  $MA(q)$  é invertível, temos:

$$(1 + \eta_1 L + \eta_2 L^2 + \dots)(1 + \theta_1 L + \theta_2 L^2 + \dots + \theta_q L^q) = 1$$

Que ao multiplicarmos, resulta em:

$$\begin{aligned} 1 &= 1 + \eta_1 L + \eta_2 L^2 + \dots \\ &\quad + \theta_1 L + \theta_1 \eta_1 L^2 + \theta_1 \eta_2 L^3 + \dots \\ &\quad + \theta_2 L^2 + \theta_2 \eta_1 L^3 + \theta_2 \eta_2 L^4 + \dots \\ &\quad \vdots \\ &\quad + \theta_q L^q + \theta_q \eta_1 L^{q+1} + \theta_q \eta_2 L^{q+2} + \dots \end{aligned}$$

Para  $j = q, q+1, \dots$  colocando os  $L^j$ 's em evidência:

$$\begin{aligned} 1 &= 1 + (\eta_1 + \theta_1) L \\ &\quad + (\eta_2 + \theta_1 \eta_1 + \theta_2) L^2 \\ &\quad + (\eta_3 + \theta_1 \eta_2 + \theta_2 \eta_1 + \theta_3) L^3 \\ &\quad \vdots \\ &\quad + (\eta_j + \theta_1 \eta_{j-1} + \dots + \theta_{q-1} \eta_1 + \theta_q) L^j \end{aligned}$$

Para  $j = q, q+1, \dots$ . Para a igualdade valer, os coeficientes dos  $L^j$ 's devem ser zero, então:

$$\begin{aligned} \eta_1 + \theta_1 &= 0 \Rightarrow \eta_1 = -\theta_1 \\ \eta_2 + \theta_1 \eta_1 + \theta_2 &= 0 \Rightarrow \eta_2 = -\theta_1 \eta_1 - \theta_2 = -\theta_2 + \theta_1^2 \\ \eta_3 + \theta_1 \eta_2 + \theta_2 \eta_1 + \theta_3 &= 0 \Rightarrow \eta_3 = -\theta_1 \eta_2 - \theta_2 \eta_1 - \theta_3 = -\theta_1^3 + 2\theta_1 \theta_2 - \theta_3 \\ &\vdots \\ \eta_j + \theta_1 \eta_{j-1} + \dots + \theta_{q-1} \eta_1 + \theta_q &= 0 \Rightarrow \eta_j = -\theta_1 \eta_{j-1} - \dots - \theta_{q-1} \eta_1 - \theta_q \end{aligned}$$

**3.7**  $AR(\infty)$ :

$$(1 + \eta_1 L + \eta_2 L^2 + \dots)(Y_t - \mu) = \varepsilon_t$$

$MA(q)$ :

$$Y_t - \mu = \left\{ \prod_{j=0}^n (1 - \lambda_j L) \right\} \left\{ \prod_{j=n+1}^q (1 - \lambda_j^{-1} L) \right\} \varepsilon_t$$

Então:

$$(1 + \eta_1 L + \eta_2 L^2 + \dots) \left\{ \prod_{j=0}^n (1 - \lambda_j L) \right\} \left\{ \prod_{j=n+1}^q (1 - \lambda_j^{-1} L) \right\} = 1$$

Efetuando a multiplicação, temos:

$$\begin{aligned}
1 &= \left\{ \prod_{j=0}^n (1 - \lambda_j L) \right\} \left\{ \prod_{j=n+1}^q (1 - \lambda_j^{-1} L) \right\} \\
&\quad + \eta_1 L \left\{ \prod_{j=0}^n (1 - \lambda_j L) \right\} \left\{ \prod_{j=n+1}^q (1 - \lambda_j^{-1} L) \right\} \\
&\quad + \eta_2 L^2 \left\{ \prod_{j=0}^n (1 - \lambda_j L) \right\} \left\{ \prod_{j=n+1}^q (1 - \lambda_j^{-1} L) \right\} \\
&\quad \vdots \\
1 &= \left\{ 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_n L^n \right\} \left\{ 1 - \frac{1}{\prod_{j=n+1}^q \lambda_j} \left[ \theta_{n+1} L + \theta_{n+2} L^2 + \cdots + \theta_q L^q \right] \right\} \\
&\quad + \eta_1 L \left\{ 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_n L^n \right\} \left\{ 1 - \frac{1}{\prod_{j=n+1}^q \lambda_j} \left[ \theta_{n+1} L + \theta_{n+2} L^2 + \cdots + \theta_q L^q \right] \right\} \\
&\quad + \eta_2 L^2 \left\{ 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_n L^n \right\} \left\{ 1 - \frac{1}{\prod_{j=n+1}^q \lambda_j} \left[ \theta_{n+1} L + \theta_{n+2} L^2 + \cdots + \theta_q L^q \right] \right\} \\
&\quad \vdots \\
1 &= \left\{ 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_n L^n - \frac{\left[ 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_n L^n \right]}{\prod_{j=n+1}^q \lambda_j} \left[ \theta_{n+1} L + \theta_{n+2} L^2 + \cdots + \theta_q L^q \right] \right\} \\
&\quad + \eta_1 L \left\{ 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_n L^n \right. \\
&\quad \quad \left. - \frac{\left[ \eta_1 L + \theta_1 L + \theta_2 L^2 + \cdots + \theta_n L^n \right]}{\prod_{j=n+1}^q \lambda_j} \left[ \theta_{n+1} L + \theta_{n+2} L^2 + \cdots + \theta_q L^q \right] \right\} \\
&\quad + \eta_2 L^2 \left\{ 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_n L^n \right. \\
&\quad \quad \left. - \frac{\left[ \eta_2 L^2 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_n L^n \right]}{\prod_{j=n+1}^q \lambda_j} \left[ \theta_{n+1} L + \theta_{n+2} L^2 + \cdots + \theta_q L^q \right] \right\} \\
&\quad \vdots
\end{aligned}$$

Como no exercício 6, devemos realizar as multiplicações e isolar os  $L^i$ 's para derivar o algoritmo dos coeficientes.

3.8

$$Y_t = (1 + 2.4L + 0.8L^2)\varepsilon_t$$

$$\begin{aligned}\Rightarrow (1 - \lambda_1 z)(1 - \lambda_2 z) &= 1 + 2.4z + 0.8z^2 \\ \lambda_1 &= -0.4, \quad \lambda_2 = -2\end{aligned}$$

Então  $1 + 2.4z + 0.8z^2 = (1 + 0.4z)(1 + 2z)$  como uma raiz,  $\lambda_2$  está fora do círculo unitário, o termo  $(1 + 0.4z)(1 + 2z)$  não é invertível. O operador invertível é

$$(1 + 0.4z)(1 + 0.5z) = (1 + 0.9z + 0.2z^2).$$

Função geradora de autocovariância e invertibilidade para um processo  $MA(2)$  :

$$\begin{aligned}g_Y(z) &= \sigma^2(1 + \theta_1 z + \theta_2 z^2)(1 + \theta_1 z^{-1} + \theta_2 z^{-2}) \\ &= \sigma^2(1 + \theta_1 z + \theta_2 z^2 + \theta_1 z^{-1} + \theta_1^2 + \theta_1 \theta_2 z + \theta_1 z^{-2} + \theta_1 \theta_2 z^{-1} + \theta_2^2 z^{-2}) \\ &= \sigma^2[1 + \theta_2 z^2 + (\theta_1 + \theta_1 \theta_2)z + (1 + \theta_1^2 + \theta_2^2)z^0 + \theta_2 z^{-2} + (\theta_1 + \theta_1 \theta_2)z^{-1}] \\ &\equiv \sigma^2[(1 - \lambda_1 z)(1 - \lambda_2 z)(1 - \lambda_1 z^{-1})(1 - \lambda_2 z^{-1})]\end{aligned}$$

Como  $\lambda_2 = -2$  está fora do círculo unitário, substituímos por seu inverso  $\lambda_2^{-1} = -0.5$ . Devemos também substituir  $\sigma^2$  por  $\sigma^2 \lambda_2^2$ . Lembrando que  $z^0 = 1$  para encontrarmos a autocovariância de ordem zero:

$$\begin{aligned}g_Y &= \sigma^2 \lambda_2^2 [(1 - \lambda_1 z)(1 - \lambda_2^{-1} z)(1 - \lambda_1 z^{-1})(1 - \lambda_2^{-1} z^{-1})] \\ &= (1)4[(1 + 0.4z)(1 + 0.5z)(1 + 0.5z^{-1})(1 + 0.5z^{-1})] \\ &= 4[(1 + 0.9z + 0.2z^2)(1 + 0.9z^{-1} + 0.2z^{-2})] \\ &= 4[z^0 + 0.9z + 0.2z^2 + 0.9z^{-1} + 0.18z^0 + 0.18z + 0.2z^{-2} + 0.018z^{-1} + 0.2z^0]\end{aligned}$$

As autocovariâncias podem ser encontradas derivando a função geradora de autocovariâncias com respeito a  $z^j$  em que  $j$  é a ordem de defasagem desejada para a autocovariância.

Lembrando que  $z^0 = 1$  para encontrarmos a autocovariância de ordem zero. Então:

$$\begin{aligned}\gamma_0 &= \frac{\partial g_Y}{\partial z^0} = 4[1 + 0.81 + 0.4] = 7.4 \\ \gamma_1 &= \frac{\partial g_Y}{\partial z^1} = 4[0.9 + 0.18] = 4.32 \\ \gamma_2 &= \frac{\partial g_Y}{\partial z^2} = 4[0.2] = 0.8\end{aligned}$$

Que são as mesmas autocovariâncias do processo  $Y_t = (1 + 2.4L + 0.8L^2)\varepsilon_t$  do exercício 1.

Podemos concluir que o processo gerado pelo operador invertível

$$(1 + 0.4z)(1 + 0.5z) = (1 + 0.9z + 0.2z^2),$$



têm a variância  $\lambda_2^2 = 4$  vezes menor que o processo gerado pelo operador não invertível  $1 + 2.4L + 0.8L^2$ . Para verificação, vamos gerar as autocovariâncias do processo invertível, conforme a fórmula padrão. Como  $\theta_1 = 0.9$ ,  $\theta_2 = 0.2$  e  $\sigma^2 = 1$ , as autocovariâncias são:

$$\begin{aligned}\bar{\gamma}_0 &= [1 + \theta_1^2 + \theta_2^2]\sigma^2 = 1 + 0.81 + 0.04 = 1.85 \\ \bar{\gamma}_1 &= [\theta_1 + \theta_1\theta_2]\sigma^2 = 0.9 + 0.18 = 1.08 \\ \bar{\gamma}_2 &= \theta_2\sigma^2 = 0.2\end{aligned}$$

Isto ocorre pois a variância,  $\sigma^2$  das  $\bar{\gamma}_s$ 's deveria ter sido substituída por  $\sigma^2\lambda_2^2$ . Conclui-se que quando existe uma raiz  $\lambda_i$  fora do círculo unitário, as autocovariâncias do processo invertível associado devem ser infladas por um fator de

$$\prod_{i=n+1}^m \lambda_i^2.$$

em que  $\lambda_n, \lambda_{n+1}, \dots, \lambda_m$  são as raízes fora do círculo unitário,  $\lambda_1, \lambda_2, \dots, \lambda_n$  são as raízes dentro do círculo unitário e  $m$  o número total de raízes.

## Capítulo 4

# Previsão

4.1 Fórmula 4.3.6:

$$\begin{aligned}
 \boldsymbol{\alpha}^{(m)'} &\equiv \begin{bmatrix} \alpha_0^{(m)} & \alpha_1^{(m)} & \alpha_2^{(m)} & \cdots & \alpha_m^{(m)} \end{bmatrix} \\
 &= \begin{bmatrix} \mu & \gamma_1 + \mu^2 & \gamma_2 + \mu^2 & \cdots & \gamma_m + \mu^2 \end{bmatrix} \\
 &\quad \times \begin{bmatrix} 1 & \mu & \mu & \cdots & \mu \\ \mu & \gamma_0 + \mu^2 & \gamma_1 + \mu^2 & \cdots & \gamma_{m-1} + \mu^2 \\ \mu & \gamma_1 + \mu^2 & \gamma_0 + \mu^2 & \cdots & \gamma_{m-2} + \mu^2 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \mu & \gamma_{m-1} + \mu^2 & \gamma_{m-2} + \mu^2 & \cdots & \gamma_0 + \mu^2 \end{bmatrix}^{-1}
 \end{aligned}$$

$$\equiv E[Y_{t+1}\mathbf{X}_t']E[\mathbf{X}_t\mathbf{X}_t']^{-1}$$

$$\text{Para } \mathbf{X}_t = \begin{bmatrix} 1 & Y_t \end{bmatrix}'$$

$$\begin{aligned}
 \boldsymbol{\alpha}^{(1)'} &= \begin{bmatrix} E[Y_{t+1}] & E[Y_{t+1}Y_t] \end{bmatrix} \times \begin{bmatrix} 1 & E[Y_t] \\ E[Y_t] & E[Y_t^2] \end{bmatrix}^{-1} \\
 &= \begin{bmatrix} \mu & \gamma_1 + \mu^2 \end{bmatrix} \times \frac{1}{\gamma_0} \begin{bmatrix} \gamma_0 + \mu^2 & -\mu \\ -\mu & 1 \end{bmatrix} \\
 &= \frac{1}{\gamma_0} \begin{bmatrix} \mu\gamma_0 + \mu^3 - \mu\gamma_1 - \mu^3 & -\mu^2 + \gamma_1 + \mu^2 \end{bmatrix} \\
 &= \frac{1}{\gamma_0} \begin{bmatrix} \mu\gamma_0 - \mu\gamma_1 & \gamma_1 \end{bmatrix} \\
 &= \begin{bmatrix} (1 - \rho_1)\mu & \rho_1 \end{bmatrix}
 \end{aligned}$$

$$\hat{E}[Y_{t+1}|Y_t] = \boldsymbol{\alpha}'\mathbf{X}_t$$

$$= \begin{bmatrix} (1 - \rho_1)\mu & \rho_1 \end{bmatrix} \begin{bmatrix} 1 \\ Y_t \end{bmatrix}$$

$$\hat{E}[Y_{t+1}|Y_t] = (1 - \rho_1)\mu + \rho_1 Y_t$$

Portanto a previsão de  $Y_{t+1}$  com base em informações somente do período  $t$  é uma média ponderada entre o valor esperado de  $Y_t$  ( $\mu$ ) e  $Y_t$ , em que o fator de ponderação é o coeficiente de autocorrelação de primeira defasagem,  $\rho_1$ .

a) Processo  $AR(1)$ :

$$Y_t = c + \phi Y_{t-1} + \varepsilon_t$$

Equação 4.2.9:

$$\hat{E}[Y_{t+s}|\varepsilon_t, \varepsilon_{t-1}, \dots] = \mu + \frac{\psi(L)}{L^s} \varepsilon_t$$

Se o processo  $AR(1)$  for invertível ele pode ser escrito da forma

$$\begin{aligned} Y_t &= \frac{c}{1 - \phi L} + \frac{\varepsilon_t}{1 - \phi L} \\ &= \mu + \psi(L)\varepsilon_t, \quad \psi(L) = 1 + \phi L + \phi^2 L^2 + \dots \end{aligned}$$

Para  $Y_{t+1}$  o processo se torna:

$$Y_{t+1} = \mu + \varepsilon_{t+1} + \phi \varepsilon_t + \phi^2 \varepsilon_{t-1} + \dots$$

O preditor linear ótimo tem a forma:

$$\hat{E}[Y_{t+1}|\varepsilon_t, \varepsilon_{t-1}, \dots] = \mu + \phi \varepsilon_t + \phi^2 \varepsilon_{t-1} + \dots$$

Dividindo  $\psi(L)$  por  $L^s$  com  $s = 1$

$$\frac{\psi(L)}{L} = L^{-1} + \phi + \phi^2 L + \dots$$

e tratando os  $L$  com expoente negativo como zero para derivar o operador de aniquilação, o preditor ótimo para um período à frente pode ser escrito em notação de operador de defasagem:

$$\hat{E}[Y_{t+1}|\varepsilon_t, \varepsilon_{t-1}, \dots] = \mu + \left[ \frac{\psi(L)}{L} \right]_+ \varepsilon_t$$

Que é idêntico à equação 4.2.9 com  $s = 1$ .

b) Processo  $MA(1)$ :

$$Y_n = \mu + \varepsilon_n + \theta \varepsilon_{n-1}$$

Equação 4.5.20:

$$\hat{E}(Y_n|Y_{n-1}, Y_{n-2}, \dots, Y_1) = \mu + \frac{\theta[1 + \theta^2 + \theta^4 + \dots + \theta^{2(n-2)}]}{[1 + \theta^2 + \theta^4 + \dots + \theta^{2(n-1)}]} \left[ Y_{n-1} - \hat{E}(Y_{n-1}|Y_{n-2}, Y_{n-3}, \dots, Y_1) \right]$$

O processo  $MA(1)$  pode ser escrito como:

$$Y_n - \mu = \varepsilon_n + \theta \varepsilon_{n-1}$$

As autocovariâncias são:

$$\begin{aligned} \gamma_0 &= E[(Y_n - \mu)^2] = E(\varepsilon_n + \theta \varepsilon_{n-1})(\varepsilon_n + \theta \varepsilon_{n-1}) = E(\varepsilon_n^2 + 2\theta \varepsilon_n \varepsilon_{n-1} + \theta^2 \varepsilon_{n-1}^2) = \sigma^2[1 + \theta^2] \\ \gamma_1 &= E[(Y_n - \mu)(Y_{n-1} - \mu)] = E[(\varepsilon_n + \theta \varepsilon_{n-1})(\varepsilon_{n-1} + \theta \varepsilon_{n-2})] \\ &= E(\varepsilon_n \varepsilon_{n-1} + \theta \varepsilon_n \varepsilon_{n-2} + \theta \varepsilon_{n-1}^2 + \theta^2 \varepsilon_{n-1} \varepsilon_{n-2}) = \sigma^2 \theta \\ \gamma_j &= 0 \quad j = 2, 3, \dots \end{aligned}$$

Temos que para  $n = 2$

$$\begin{aligned}\hat{E}(Y_2|Y_1) &= \mu + \text{Cov}(Y_2, Y_1)\text{Var}(Y_2^2)^{-1}(Y_1 - \hat{E}(Y_1)) \\ &= \mu + \frac{\theta}{1 + \theta^2}(Y_1 - \hat{E}(Y_1))\end{aligned}$$

Que é idêntico à equação 4.5.20 com  $n = 2$ .

c) Dado que

$$\hat{E}[Y_{t+1}|Y_t] = (1 - \rho_1)\mu + \rho_1 Y_t$$

Podemos rearranjar a expressão e obter

$$\hat{E}[Y_{t+1}|Y_t] = \mu + \rho_1(Y_t - \mu)$$

Como o coeficiente de correlação de primeira defasagem de um processo  $AR(2)$  é

$$\rho_1 = \frac{\phi_1}{1 - \phi_2}$$

O preditor se torna

$$\hat{E}[Y_{t+1}|Y_t] = \mu + \frac{\phi_1}{1 - \phi_2}(Y_t - \mu)$$

O resíduo desta predição é

$$\begin{aligned}\bar{Y}_{t+1|t} &= Y_{t+1} - \left[ \mu + \frac{\phi_1}{1 - \phi_2}(Y_t - \mu) \right] \\ &= \mu + \phi_1 Y_t + \phi_2 Y_{t-1} + \varepsilon_{t+1} - \mu - \frac{\phi_1}{1 - \phi_2}(Y_t - \mu) \\ &= \frac{\phi_1}{1 - \phi_2}\mu - \left( \frac{\phi_1 \phi_2}{1 - \phi_2} \right) Y_t + \phi_2 Y_{t-1} + \varepsilon_{t+1}\end{aligned}$$

Verificando correlação entre resíduo e valores defasados:

$$\begin{aligned}E(\bar{Y}_{t+1|t} Y_t) &= E \left\{ \left[ \frac{\phi_1}{1 - \phi_2}\mu - \left( \frac{\phi_1 \phi_2}{1 - \phi_2} \right) Y_t + \phi_2 Y_{t-1} + \varepsilon_{t+1} \right] \left[ \mu + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t \right] \right\} \\ &\neq 0\end{aligned}$$

Então,  $\hat{Y}_{t+1|t}$  e  $Y_t$  são correlacionados.

$$\begin{aligned}E(\bar{Y}_{t+1|t} Y_{-1}) &= E \left\{ \left[ \frac{\phi_1}{1 - \phi_2}\mu - \left( \frac{\phi_1 \phi_2}{1 - \phi_2} \right) Y_t + \phi_2 Y_{t-1} + \varepsilon_{t+1} \right] \left[ \mu + \phi_1 Y_{t-2} + \phi_2 Y_{t-3} + \varepsilon_{t-1} \right] \right\} \\ &\neq 0\end{aligned}$$

Então,  $\hat{Y}_{t+1|t}$  e  $Y_{t-1}$  também são correlacionados.

**4.2** Como  $s = q = 1$ , temos um processo  $MA(1)$ :

$$Y_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}$$

E a predição a ser realizada para um período à frente:

$$E[Y_{t+1}|Y_t].$$

Dado que o processo  $MA(1)$  possa ser escrito na forma

$$Y_t - \mu = (1 + \theta L)\varepsilon_t.$$

Sendo a fórmula de predição de *Wiener-Kolmogorov* para  $s = 1$ :

$$\hat{Y}_{t+1|t} = \mu + \left[ \frac{\psi(L)}{L} \right]_+ \varepsilon_t$$

Substituindo o processo

$$MA(1)$$

na fórmula temos:

$$\hat{Y}_{t+1|t} = \mu + \left[ \frac{1 + \theta L}{L} \right]_+ \frac{(Y_t - \mu)}{1 + \theta L}$$

Para o processo  $MA(1)$ :

$$\left[ \frac{1 + \theta L}{L} \right]_+ = \theta$$

Então podemos escrever a fórmula de *Wiener-Kolmogorov* como

$$\hat{Y}_{t+1|t} = \mu + \theta \frac{(Y_t - \mu)}{1 + \theta L}$$

Expandindo a soma infinita representada:

$$\hat{Y}_{t+1|t} = \mu + \theta(Y_t - \mu) - \theta^2(Y_{t-1} - \mu) + \theta^3(Y_{t-2} - \mu) - \dots + (-1)^{m-1}\theta^m(Y_{t-m+1} - \mu)$$

Equivalente à equação 4.3.3.

4.3

$$\begin{aligned} \mathbf{\Omega} &= \begin{bmatrix} 1 & -2 & 3 \\ -2 & 6 & -4 \\ 3 & -4 & 12 \end{bmatrix} \\ \mathbf{E}_1 &= \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -3 & 0 & 1 \end{bmatrix} \\ \mathbf{E}_1 \mathbf{\Omega} \mathbf{E}_1' &= \mathbf{H} = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -3 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & -2 & 3 \\ -2 & 6 & -4 \\ 3 & -4 & 12 \end{bmatrix} \begin{bmatrix} 1 & 2 & -3 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & -2 & 3 \\ 0 & 2 & 2 \\ 0 & 2 & 3 \end{bmatrix} \begin{bmatrix} 1 & 2 & -3 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 2 \\ 0 & 2 & 3 \end{bmatrix} \end{aligned}$$

$$\begin{aligned}
\mathbf{E}_2 &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \\
\mathbf{E}_2 \mathbf{H} \mathbf{E}_2' &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 2 \\ 0 & 2 & 3 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & -1 \\ 0 & 0 & 1 \end{bmatrix} \\
&= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 2 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & -1 \\ 0 & 0 & 1 \end{bmatrix} \\
&= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{bmatrix}
\end{aligned}$$

$$\begin{aligned}
\mathbf{E}_2 \mathbf{E}_1 \mathbf{\Omega} \mathbf{E}_1' \mathbf{E}_2' &= \mathbf{E}_2 \mathbf{E}_1 \mathbf{\Omega} (\mathbf{E}_2 \mathbf{E}_1)' = \mathbf{A}^{-1} \mathbf{\Omega} \mathbf{A}'^{-1} = \mathbf{D} \\
\mathbf{\Omega} &= \mathbf{A} \mathbf{D} \mathbf{A}'
\end{aligned}$$

$$\begin{aligned}
\mathbf{A} = (\mathbf{E}_2 \mathbf{E}_1)^{-1} &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -3 & 0 & 1 \end{bmatrix}^{-1} \\
&= \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -5 & -1 & 1 \end{bmatrix}^{-1} \\
&= \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 3 & 1 & 1 \end{bmatrix}
\end{aligned}$$

$$\mathbf{A} \mathbf{\Omega} \mathbf{A}' = \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 3 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & -2 & 3 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}$$

**4.4** Não pois o coeficiente de  $Y_2$  da projecção linear de  $Y_4$  contra  $Y_3$ ,  $Y_2$  e  $Y_1$  é:

Dado que

$$Y_4 = \bar{Y}_4 + k_{43} k_{33}^{-1} \bar{Y}_3 + h_{41} h_{22}^{-1} \bar{Y}_2 + \Omega_{41} \Omega_{11}^{-1} \bar{Y}_1,$$

temos ainda que:

$$\bar{Y}_1 = Y_1,$$

$$\bar{Y}_2 = Y_2 - \Omega_{21} \Omega_{11}^{-1} \bar{Y}_1$$

$$\bar{Y}_3 = Y_3 - \Omega_{31} \Omega_{11}^{-1} Y_1 - h_{32} h_{22}^{-1} (Y_2 - \Omega_{21} \Omega_{11}^{-1} \bar{Y}_1)$$

Substituindo em  $Y_4$  nos dá:

$$\begin{aligned}
Y_4 &= \bar{Y}_4 + k_{43} k_{33}^{-1} (Y_3 - \Omega_{31} \Omega_{11}^{-1} Y_1 - h_{32} h_{22}^{-1} (Y_2 - \Omega_{21} \Omega_{11}^{-1} Y_1)) \\
&\quad + h_{41} h_{22}^{-1} (Y_2 - \Omega_{21} \Omega_{11}^{-1} Y_1) + \Omega_{41} \Omega_{11}^{-1} Y_1
\end{aligned}$$

Podemos observar que o coeficiente de  $Y_2$  é

$$h_{41} h_{22}^{-1} - k_{43} k_{33}^{-1} h_{32} h_{22}^{-1}$$

Já o elemento  $(4, 2)$  de  $\mathbf{A}$  é

$$h_{41}h_{22}^{-1}$$

Dado que  $k_{43}k_{33}^{-1}h_{32}h_{22}^{-1} \neq 0$ , os termos são diferentes e a resposta é não.

**4.5** Se  $X_t$  segue um processo  $AR(p)$  ele pode ser representado na forma

$$\begin{aligned} X_t &= \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + \varepsilon_t. \\ X_t &= \frac{\varepsilon_t}{1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p} \end{aligned}$$

Com  $\varepsilon_t$  sendo um *ruído branco*. Então o processo  $Y_t = X_t + \nu_t$  se torna

$$Y_t = \frac{\varepsilon_t}{1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p} + \nu_t.$$

Que por sua vez pode ser escrito como

$$\begin{aligned} Y_t &= \frac{\varepsilon_t + (1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p)\nu_t}{(1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p)} \\ &= \frac{\varepsilon_t + \nu_t - \phi_1 \nu_{t-1} - \phi_2 \nu_{t-2} - \cdots - \phi_p \nu_{t-p}}{(1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p)}. \end{aligned}$$

Que é um processo  $ARMA(p, p)$  com  $\theta_i = -\phi_i$ ,  $i = 1, 2, \dots, p$ .

**4.6** Se  $X_t$  segue um processo  $AR(p)$  ele pode ser representado na forma

$$\begin{aligned} X_t &= \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + \varepsilon_t. \\ X_t &= \frac{\varepsilon_t}{1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p} \end{aligned}$$

Com  $\varepsilon_t$  sendo um *ruído branco*. Se  $Z_t$  segue um processo  $MA(q)$ , ele pode ser escrito como

$$\begin{aligned} Z_t &= \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \cdots + \theta_q \epsilon_{t-q} \\ &= (1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_q L^q) \epsilon_t \end{aligned}$$

Somando os dois processos temos:

$$\begin{aligned} Y_t &= X_t + Z_t \\ &= \frac{\varepsilon_t}{1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p} + (1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_q L^q) \epsilon_t \\ &= \frac{\varepsilon_t + (1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p)(1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_q L^q) \epsilon_t}{1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p} \end{aligned}$$

Expandindo o termo  $(1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p)(1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_q L^q)$  temos:

$$\begin{aligned}
& 1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p \\
& + \theta_1 L - \theta_1 \phi_1 L^2 - \theta_1 \phi_2 L^3 - \dots - \theta_1 \phi_p L^{p+1} \\
& + \theta_2 L^2 - \theta_2 \phi_1 L^3 - \theta_2 \phi_2 L^4 - \dots - \theta_2 \phi_p L^{p+2} \\
& + \vdots \\
& + \theta_q L^q - \theta_q \phi_1 L^{1+q} - \theta_q \phi_2 L^{2+q} - \dots - \theta_q \phi_p L^{p+q}
\end{aligned}$$

Então a maior ordem de defasagem de  $\epsilon_{t-j}$  é  $p+q$ ,  $j = 0, 1, 2, \dots, p+q$ . Com isso o processo  $Y_t$  é um processo  $ARMA(p, p+q)$ .



## Capítulo 5

# Estimação de Máxima Verossimilhança

5.1 Equação 5.4.16:

$$\mathcal{L}(\boldsymbol{\theta}) = \log f_{\mathbf{Y}}(\mathbf{y}; \boldsymbol{\theta}) = -\frac{T}{2} \log(2\pi) - \frac{1}{2} \sum_{t=1}^T \log(d_{tt}) - \frac{1}{2} \sum_{t=1}^T \frac{\bar{y}_t^2}{d_{tt}}.$$

os termos que possuem  $\theta$  e  $\sigma^2$  são as equações 5.4.11

$$\bar{y} = y_t - \mu - \frac{\theta[1 + \theta^2 + \theta^4 + \dots + \theta^{2(t-2)}]}{[1 + \theta^2 + \theta^4 + \dots + \theta^{2(t-1)}]} \bar{y}_{t-1},$$

e 5.4.12

$$d_{tt} = E(\bar{Y}_t^2) = \sigma^2 \frac{1 + \theta^2 + \theta^4 + \dots + \theta^{2t}}{1 + \theta^2 + \theta^4 + \dots + \theta^{2(t-1)}}.$$

as duas equações são compostas por uma razão de somas finitas, com isso temos:

$$\begin{aligned} \frac{\theta[1 + \theta^2 + \theta^4 + \dots + \theta^{2(t-2)}]}{[1 + \theta^2 + \theta^4 + \dots + \theta^{2(t-1)}]} &= \frac{\theta \left[ \frac{1 - \theta^{2(t-2)}}{1 - \theta^2} \right]}{\frac{1 - \theta^{2(t-1)}}{1 - \theta^2}} \\ &= \theta \frac{[1 - \theta^{2(t-2)}]}{1 - \theta^{2(t-1)}} \end{aligned}$$

e

$$\begin{aligned} \frac{1 + \theta^2 + \theta^4 + \dots + \theta^{2t}}{1 + \theta^2 + \theta^4 + \dots + \theta^{2(t-1)}} &= \frac{\frac{1 - \theta^{2t}}{1 - \theta^2}}{\frac{1 - \theta^{2(t-1)}}{1 - \theta^2}} \\ &= \frac{1 - \theta^{2t}}{1 - \theta^{2(t-1)}} \end{aligned}$$

Se  $\sigma^2 = \bar{\sigma}^2$  e  $\theta = \bar{\theta}$ , então:

$$\begin{aligned} \bar{y} &= y_t - \mu - \frac{\bar{\theta}[1 + \bar{\theta}^2 + \bar{\theta}^4 + \dots + \bar{\theta}^{2(t-2)}]}{[1 + \bar{\theta}^2 + \bar{\theta}^4 + \dots + \bar{\theta}^{2(t-1)}]} \bar{y}_{t-1}, \\ &= y_t - \mu - \bar{\theta} \frac{[1 - \bar{\theta}^{2(t-2)}]}{1 - \bar{\theta}^{2(t-1)}} \bar{y}_{t-1} \end{aligned}$$

$$\begin{aligned}
d_{tt} &= E(\bar{Y}_t^2) = \bar{\sigma}^2 \frac{1 + \bar{\theta}^2 + \bar{\theta}^4 + \dots + \bar{\theta}^{2t}}{1 + \bar{\theta}^2 + \bar{\theta}^4 + \dots + \bar{\theta}^{2(t-1)}} \\
&= \bar{\sigma}^2 \frac{1 - \bar{\theta}^{2t}}{1 - \bar{\theta}^{2(t-1)}}
\end{aligned}$$

Agora se  $\sigma^2 = \bar{\theta}^2 \bar{\sigma}^2$  e  $\theta = \bar{\theta}^{-1}$ :

$$\begin{aligned}
\bar{y} &= y_t - \mu - \frac{\bar{\theta}^{-1}[1 + \bar{\theta}^{-2} + \bar{\theta}^{-4} + \dots + \bar{\theta}^{-2(t-2)}]}{[1 + \bar{\theta}^{-2} + \bar{\theta}^{-4} + \dots + \bar{\theta}^{-2(t-1)}]} \bar{y}_{t-1}, \\
&= y_t - \mu - \bar{\theta}^{-1} \frac{[1 - \bar{\theta}^{-2(t-2)}]}{1 - \bar{\theta}^{-2(t-1)}} \bar{y}_{t-1}
\end{aligned}$$

$$\begin{aligned}
d_{tt} &= E(\bar{Y}_t^2) = \bar{\theta} \bar{\sigma}^2 \frac{1 + \bar{\theta}^{-2} + \bar{\theta}^{-4} + \dots + \bar{\theta}^{-2t}}{1 + \bar{\theta}^{-2} + \bar{\theta}^{-4} + \dots + \bar{\theta}^{-2(t-1)}} \\
&= \bar{\theta}^2 \bar{\sigma}^2 \frac{1 - \bar{\theta}^{-2t}}{1 - \bar{\theta}^{-2(t-1)}}
\end{aligned}$$

As duas formas são equivalentes pois

$$\bar{\theta}^{-1} \frac{[1 - \bar{\theta}^{-2(t-2)}]}{1 - \bar{\theta}^{-2(t-1)}} \equiv \bar{\theta} \frac{[1 - \bar{\theta}^{2(t-2)}]}{1 - \bar{\theta}^{2(t-1)}}$$

e

$$\bar{\theta}^2 \frac{1 - \bar{\theta}^{-2t}}{1 - \bar{\theta}^{-2(t-1)}} \equiv \frac{1 - \bar{\theta}^{2t}}{1 - \bar{\theta}^{2(t-1)}} \quad \blacksquare$$

**5.2** Equação 5.7.6:

$$\mathcal{L}(\boldsymbol{\theta}) = -1.5\theta_1^2 - 2\theta_2^2$$

Equação 5.7.12:

$$\boldsymbol{\theta}^{(1)} - \boldsymbol{\theta}^{(0)} = [\mathbf{H}(\boldsymbol{\theta}^{(0)})]^{-1} \mathbf{g}(\boldsymbol{\theta}^{(0)}).$$

Dado que  $\boldsymbol{\theta}^{(0)} = [-1, 1]'$ .

$$\begin{aligned}
\mathbf{g}(\boldsymbol{\theta}) &= \begin{bmatrix} -3\theta_1 \\ -4\theta_2 \end{bmatrix} \Rightarrow \mathbf{g}(\boldsymbol{\theta}^{(0)}) = \begin{bmatrix} 3 \\ -4 \end{bmatrix} \\
\mathbf{H}(\boldsymbol{\theta}^{(0)}) &= \begin{bmatrix} 3 & 0 \\ 0 & 4 \end{bmatrix} \Rightarrow [\mathbf{H}(\boldsymbol{\theta}^{(0)})]^{-1} = \frac{1}{12} \begin{bmatrix} 4 & 0 \\ 0 & 3 \end{bmatrix}
\end{aligned}$$

$$\begin{aligned}
\boldsymbol{\theta}^{(1)} - \boldsymbol{\theta}^{(0)} &= [\mathbf{H}(\boldsymbol{\theta}^{(0)})]^{-1} \mathbf{g}(\boldsymbol{\theta}^{(0)}) \Rightarrow \\
\boldsymbol{\theta}^{(1)} &= \begin{bmatrix} -1 \\ 1 \end{bmatrix} + \begin{bmatrix} 1/3 & 0 \\ 0 & 1/4 \end{bmatrix} \begin{bmatrix} 3 \\ -4 \end{bmatrix} \\
&= \begin{bmatrix} -1 \\ 1 \end{bmatrix} + \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\
&= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \quad \blacksquare
\end{aligned}$$

5.3 a)

$$\mathcal{L}(\mu, \sigma^2; y_1, y_2, \dots, y_T) = -\frac{T}{2} \log(2\pi) - \frac{T}{2} \log(\sigma^2) - \sum_{t=1}^T \frac{(y_t - \mu)^2}{2\sigma^2}$$

$$\frac{\partial \mathcal{L}}{\partial \mu} = 0 \Rightarrow \sum_{t=1}^T \frac{2(y_t - \mu)}{2\sigma^2} = 0,$$

$$\sum_{t=1}^T y_t = T\mu \Rightarrow \hat{\mu} = T^{-1} \sum_{t=1}^T y_t$$

$$\frac{\partial \mathcal{L}}{\partial \sigma^2} = 0 \Rightarrow -\frac{T}{2\sigma^2} - \left[ -\sum_{t=1}^T \frac{2(y_t - \mu)^2}{4\sigma^4} \right] = 0,$$

$$\frac{T}{2\sigma^2} = \frac{1}{2\sigma^4} \sum_{t=1}^T (y_t - \mu)^2 \Rightarrow \hat{\sigma}^2 = T^{-1} \sum_{t=1}^T (y_t - \hat{\mu})^2 \quad \blacksquare$$

b)

$$\frac{\partial^2 \mathcal{L}}{\partial \mu^2} = -\sum_{t=1}^T \frac{2}{2\sigma^2} = -\frac{T}{\sigma^2}$$

$$\frac{\partial^2 \mathcal{L}}{\partial \sigma^2 \partial \mu} = -\sum_{t=1}^T \frac{4(y_t - \mu)}{4\sigma^4} = -\sum_{t=1}^T \frac{(y_t - \mu)}{\sigma^4}$$

$$\frac{\partial^2 \mathcal{L}}{\partial (\sigma^2)^2} = \frac{2T}{4\sigma^4} - \sum_{t=1}^T \frac{4\sigma^2(y_t - \mu)^2}{4\sigma^8} = \frac{T}{2\sigma^4} - \sum_{t=1}^T \frac{(y_t - \mu)^2}{\sigma^6}$$

$$\frac{\partial^2 \mathcal{L}}{\partial \mu \partial \sigma^2} = -\sum_{t=1}^T \frac{4(y_t - \mu)}{4\sigma^4} = -\sum_{t=1}^T \frac{(y_t - \mu)}{\sigma^4}$$

Então a matriz Hessiana fica:

$$\frac{\partial^2 \mathcal{L}(\boldsymbol{\theta})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'} = \begin{bmatrix} -\frac{T}{\sigma^2} & -\sum_{t=1}^T \frac{(y_t - \mu)}{\sigma^4} \\ -\sum_{t=1}^T \frac{(y_t - \mu)}{\sigma^4} & \frac{T}{2\sigma^4} - \sum_{t=1}^T \frac{(y_t - \mu)^2}{\sigma^6} \end{bmatrix}$$

Se multiplicada por  $T^{-1}$  e avaliada em  $\boldsymbol{\theta} = \hat{\boldsymbol{\theta}}$ :

$$\hat{\mathcal{J}}_{2D} = -T^{-1} \frac{\partial^2 \mathcal{L}(\boldsymbol{\theta})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'} \Big|_{\boldsymbol{\theta} = \hat{\boldsymbol{\theta}}} = E \left\{ -T^{-1} \begin{bmatrix} -\frac{T}{\sigma^2} & -\sum_{t=1}^T \frac{(y_t - \mu)}{\sigma^4} \\ -\sum_{t=1}^T \frac{(y_t - \mu)}{\sigma^4} & \frac{T}{2\sigma^4} - \sum_{t=1}^T \frac{(y_t - \mu)^2}{\sigma^6} \end{bmatrix} \right\}$$

Dado que  $E[y_t] = \mu$  e  $E[(y_t - \mu)^2] = \sigma^2$ :

$$\hat{\mathcal{J}}_{2D} = \begin{bmatrix} 1/\sigma^2 & 0 \\ 0 & 1/2\sigma^4 \end{bmatrix} \quad \blacksquare$$

c) A inversa de  $\hat{\mathcal{J}}_{2D}$  é:

$$\hat{\mathcal{J}}_{2D}^{-1} = 2\sigma^6 \begin{bmatrix} 1/2\sigma^4 & 0 \\ 0 & 1/\sigma^2 \end{bmatrix} = \begin{bmatrix} \sigma^2 & 0 \\ 0 & 2\sigma^4 \end{bmatrix}$$

Multiplicando por  $T^{-1}$ :

$$T^{-1} \hat{\mathcal{J}}_{2D}^{-1} = \begin{bmatrix} \sigma^2/T & 0 \\ 0 & 2\sigma^4/T \end{bmatrix}$$

com isso:

$$\begin{bmatrix} \hat{\mu} \\ \hat{\sigma}^2 \end{bmatrix} \approx N \left( \begin{bmatrix} \mu \\ \sigma^2 \end{bmatrix}, \begin{bmatrix} \sigma^2/T & 0 \\ 0 & 2\sigma^4/T \end{bmatrix} \right) \quad \blacksquare$$

# Capítulo 6

## Análise Spectral

6.1 Equação 6.1.12:

$$s_Y(\omega) = (2\pi)^{-1} \sigma^2 [1 + \theta^2 + 2\theta \cos(\omega)].$$

equação 6.1.6:

$$s_Y(\omega) = \frac{1}{2\pi} \left\{ \gamma_0 + 2 \sum_{j=1}^{\infty} \gamma_j \cos(\omega j) \right\}.$$

Autocovariâncias de um processo  $MA(1)$ :

$$\gamma_0 = \sigma^2 [1 + \theta^2]$$

$$\gamma_1 = \sigma^2 \theta$$

$$\gamma_k = 0 \quad k \geq 2$$

Substituindo as autocovariâncias na equação 6.1.6, temos:

$$\begin{aligned} s_Y(\omega) &= \frac{1}{2\pi} \left\{ \sigma^2 [1 + \theta^2] + 2\sigma^2 \theta \cos(\omega) \right\} \\ &= 2\pi^{-1} \sigma^2 [1 + \theta^2 + 2\theta \cos(\omega)] \quad \blacksquare \end{aligned}$$

6.2 Equação 6.1.9:

$$s_Y(\omega) = \frac{\sigma^2}{2\pi}$$

Equação 6.1.12:

$$s_Y(\omega) = (2\pi)^{-1} \sigma^2 [1 + \theta^2 + 2\theta \cos(\omega)].$$

Equação 6.1.17:

$$\int_{-\pi}^{\pi} s_Y(\omega) d\omega = \gamma_0$$

Integrando 6.1.9:

$$\begin{aligned} \int_{-\pi}^{\pi} \frac{\sigma^2}{2\pi} d\omega &= \frac{\sigma^2}{2\pi} \left[ \omega \right]_{-\pi}^{\pi} \\ &= \frac{\sigma^2}{2\pi} [\pi - (-\pi)] \\ &= \frac{\sigma^2}{2\pi} 2\pi \\ &= \sigma^2 \end{aligned}$$

Integrando 6.1.12:

$$\begin{aligned}
 \int_{-\pi}^{\pi} (2\pi)^{-1} \sigma^2 [1 + \theta^2 + 2\theta \cos(\omega)] d\omega &= (2\pi)^{-1} \sigma^2 \left[ \omega + \theta^2 \omega + 2\theta \operatorname{sen}(\omega) \right]_{-\pi}^{\pi} \\
 &= (2\pi)^{-1} \sigma^2 \left[ (\pi + \theta^2 \pi + 2\theta \operatorname{sen}(\pi)) - (-\pi + \theta^2(-\pi) + 2\theta \operatorname{sen}(-\pi)) \right] \\
 &= (2\pi)^{-1} \sigma^2 \left[ (\pi + \theta^2 \pi + 2\theta \operatorname{sen}(\pi)) + \pi + \theta^2 \pi - 2\theta \operatorname{sen}(-\pi) \right] \\
 &= (2\pi)^{-1} \sigma^2 \left[ 2\pi(1 + \theta^2) \right] \\
 &= \sigma^2 [1 + \theta^2]
 \end{aligned}$$

Já que  $\operatorname{sen}(\pi) = \operatorname{sen}(-\pi) = 0$ . ■

## Capítulo 7

# Teoria de distribuição assintótica

**7.1** Por continuidade,  $|g(X_T, c_T) - g(\xi, c)| > \delta$  somente se  $|X_T - \xi| + |c_T - c| > \eta$  para algum  $\eta$ . Mas  $c_T \rightarrow c$  e  $X_T \xrightarrow{p} \xi$  significa que existe um  $N$  tal que  $|c_T - c| < \eta/2$  para todo  $T \geq N$ , com isso  $P\{|c_T - c| > \eta/2\} = 0$ , e tal que  $P\{|X_T - \xi| > \eta/2\} < \varepsilon$  para todo  $T \geq N$ . Então  $P\{|X_T - \xi| + |c_T - c| > \eta\}$  é menor que  $\varepsilon$  para todo  $T \geq N$ , implicando que  $P\{|g(X_T, c_T) - g(\xi, c)| > \delta\} < \varepsilon$ . ■

**7.2** a)

$$\begin{aligned}
 Y_t &= \sum_{i=0}^{\infty} 0.8^i \varepsilon_{t-i} = \kappa_t \\
 \bar{Y}_t &= \frac{1}{T} \sum_{t=1}^T \kappa_t \\
 \text{Var}[\bar{Y}_t] &= E[\bar{Y}_t^2] - E[\bar{Y}_t]^2, \text{ dado que } E[\bar{Y}_t] = 0 \\
 \text{Var}[\bar{Y}_t] &= E[\bar{Y}_t^2] = E\left\{\left[\frac{1}{T} \sum_{t=1}^T \kappa_t\right]^2\right\} \\
 &= \frac{1}{T^2} E \sum_{t=1}^T \left[ (\varepsilon_t + 0.8\varepsilon_{t-1} + 0.8^2\varepsilon_{t-2} + \dots)(\varepsilon_t + 0.8\varepsilon_{t-1} + 0.8^2\varepsilon_{t-2} + \dots) \right] \\
 &= \frac{1}{T^2} E \sum_{t=1}^T \left[ \varepsilon_t^2 + 0.8\varepsilon_t\varepsilon_{t-1} + 0.8^2\varepsilon_t\varepsilon_{t-2} + \dots + 0.8\varepsilon_t\varepsilon_{t-1} + 0.8^2\varepsilon_{t-1}^2 + 0.8^3\varepsilon_{t-1}\varepsilon_{t-2} + \dots \right] \\
 &= \frac{1}{T^2} \sum_{t=1}^T \left[ 1 + 0.8^2 + 0.8^4 + 0.8^6 + \dots \right] \\
 &= \frac{1}{T^2} \frac{T}{1 - 0.8^2} = \frac{2.77}{T} \\
 \lim_{T \rightarrow \infty} T \cdot \text{Var}[\bar{Y}_t] &= \lim_{T \rightarrow \infty} T \cdot \frac{2.77}{T} = \blacksquare
 \end{aligned}$$

b) De uma distribuição normal padronizada, o valor da variável  $z$  que possui 95% de confiança é 1.645. Portanto:

$$1.645 = 0.1 \frac{\sqrt{T}}{\sqrt{2.77}} \Rightarrow T = 751,67$$

Então a amostra deve ter mais de 751 observações. ■

**7.3** Não, pois uma sequência de diferença *martingale* possui variância que pode depender do tempo.

[7.4] Sim, pois uma sequência de diferença *martingale* possui média zero, porém, com a adição do fato de que sua variância seja constante (não dependente do tempo),  $Y_t$  se torna estacionário em covariância.

[7.5] Uma sequência  $\{Y_t\}$  é *uniformemente integrável* se para cada  $\varepsilon > 0$ , existe um  $c > 0$  tal que

$$E(|Y_t| \cdot \delta_{[|Y_t| \geq c]}) < \varepsilon$$

Para todo  $t$ , onde  $\delta_{[|Y_t| \geq c]} = 1$  se  $|Y_t| \geq c$  e 0 caso contrário.

Para a variável aleatória de interesse temos:

$$\begin{aligned} E(|X_{t,k}| \cdot \delta_{[|Y_t| \geq c]}) &= E\left(\left|\sum_{u=0}^{\infty} \sum_{v=0}^{\infty} \psi_u \psi_v [\varepsilon_{t-u} \varepsilon_{t-k-v} - E(\varepsilon_{t-u} \varepsilon_{t-k-v})]\right| \cdot \delta_{[|Y_t| \geq c]}\right) \\ &\leq E\left(\sum_{u=0}^{\infty} \sum_{v=0}^{\infty} \left|\psi_u \psi_v\right| \left|\varepsilon_{t-u} \varepsilon_{t-k-v} - E(\varepsilon_{t-u} \varepsilon_{t-k-v})\right| \cdot \delta_{[|Y_t| \geq c]}\right) \end{aligned}$$

Como  $\{\psi_j\}_{j=0}^{\infty}$  é absolutamente somável podemos colocar o operador de esperança dentro do somatório.

$$\begin{aligned} E(|X_{t,k}| \cdot \delta_{[|Y_t| \geq c]}) &= \sum_{u=0}^{\infty} \sum_{v=0}^{\infty} E\left|\psi_u \psi_v\right| \left|\varepsilon_{t-u} \varepsilon_{t-k-v} - E(\varepsilon_{t-u} \varepsilon_{t-k-v})\right| \cdot \delta_{[|Y_t| \geq c]} \\ &\leq \sum_{u=0}^{\infty} \sum_{v=0}^{\infty} \left|\psi_u \psi_v\right| \left\{E\left|\varepsilon_{t-u} \varepsilon_{t-k-v} - E(\varepsilon_{t-u} \varepsilon_{t-k-v})\right|^r\right\}^{1/r} \times \left\{\frac{E|Y_{t,k}|}{c}\right\}^{(r-1)/r} \end{aligned}$$

Em que a última desigualdade segue os mesmo argumentos de 7.A.6. Portanto

$$E(|X_{t,k}| \cdot \delta_{[|Y_t| \geq c]}) \leq \sum_{u=0}^{\infty} \sum_{v=0}^{\infty} \left|\psi_u \psi_v\right| \left\{M'\right\}^{1/r} \times \left\{\frac{E|X_{t,k}|}{c}\right\}^{(r-1)/r}$$

Dado que  $E|X_{t,k}|$  seja limitado:

$$\begin{aligned} E|X_{t,k}| &= E\left|\sum_{u=0}^{\infty} \sum_{v=0}^{\infty} \psi_u \psi_v [\varepsilon_{t-u} \varepsilon_{t-k-v} - E(\varepsilon_{t-u} \varepsilon_{t-k-v})]\right| \\ &\leq \sum_{u=0}^{\infty} \sum_{v=0}^{\infty} \left|\psi_u \psi_v\right| E\left|\varepsilon_{t-u} \varepsilon_{t-k-v} - E(\varepsilon_{t-u} \varepsilon_{t-k-v})\right| \\ &= K \end{aligned}$$

Temos que:

$$E(|X_{t,k}| \cdot \delta_{[|Y_t| \geq c]}) \leq \sum_{u=0}^{\infty} \sum_{v=0}^{\infty} \left|\psi_u \psi_v\right| \left\{M'\right\}^{1/r} \times \left\{\frac{K}{c}\right\}^{(r-1)/r}$$

Desde que  $\{\psi_j\}_{j=0}^{\infty}$  seja absolutamente somável, o lado direito da desigualdade pode ser suficientemente pequeno ( $< \varepsilon$ ) se escolhermos  $c$  suficientemente grande. ■



**7.6** Pela proposição 7.1, só é preciso mostrar que  $\bar{Y}_t \xrightarrow{p} \mu$ . Como a variância de  $\bar{Y}_t$  converge para zero quando  $t$  tende ao infinito ( $\sigma^2/T \rightarrow 0$ ) e  $\bar{Y}_t \rightarrow \mu$ ,  $\bar{Y}_t$  converge em média quadrática para  $\mu$  e portanto também converge em probabilidade.

**7.7** a) Podemos mostrar que

$$\frac{1}{T} \sum_{t=1}^T Y_t \xrightarrow{m.s.} \mu.$$

Ou seja, que

$$E\left(\frac{1}{T} \sum_{t=1}^T Y_t - \mu\right)^2 < \varepsilon.$$

Pela lei dos grandes números para observações serialmente correlacionadas (seção 7.2) temos que  $E(\bar{Y}_T - \mu)^2 \rightarrow 0$ . Portanto  $\bar{Y}_T \xrightarrow{m.s.} \mu$ , o que implica em

$$\frac{1}{T} \sum_{t=1}^T Y_t \xrightarrow{p} \mu. \quad \blacksquare$$

b) Note que  $E|\varepsilon_t|^r < \infty$  para  $r = 4$ , tal que 7.2.14 estabelece

$$\frac{1}{T-k} \sum_{t=k+1}^T \bar{Y}_t \bar{Y}_{t-k} \xrightarrow{p} E(\bar{Y}_t \bar{Y}_{t-k}).$$

Onde  $\bar{Y}_t \equiv Y_t - \mu$ . Mas

$$\begin{aligned} \frac{1}{T-k} \sum_{t=k+1}^T Y_t Y_{t-k} &= \frac{1}{T-k} \sum_{t=k+1}^T (\bar{Y}_t + \mu)(\bar{Y}_{t-k} + \mu) \\ &= \frac{1}{T-k} \sum_{t=k+1}^T \bar{Y}_t \bar{Y}_{t-k} + \mu \frac{1}{T-k} \sum_{t=k+1}^T \bar{Y}_{t-k} + \mu \frac{1}{T-k} \sum_{t=k+1}^T \bar{Y}_{t-k} + \mu^2 \\ &= E(\bar{Y}_t + \mu)(\bar{Y}_{t-k} + \mu) \\ &= E(Y_t Y_{t-k}). \quad \blacksquare \end{aligned}$$

## Capítulo 10

# Processos Vetoriais Estacionários em Covariância

**10.1** Equação 10.2.19:

$$\text{vec} \begin{bmatrix} \Gamma_0 & \Gamma_1 & \cdots & \Gamma_{p-1} \\ \Gamma'_1 & \Gamma_0 & \cdots & \Gamma_{p-2} \\ \vdots & \vdots & \vdots & \vdots \\ \Gamma'_{p-1} & \Gamma'_{p-2} & \cdots & \Gamma_0 \end{bmatrix} = [\mathbf{I}_{r^2} - \mathcal{A}]^{-1} \text{vec}(\mathbf{Q}).$$

Sendo que  $r = np$  e

$$\mathcal{A} \equiv \mathbf{F}_{(r \times r)} \otimes \mathbf{F}_{(r \times r)}$$

Um processo escalar ( $n = 1$ )  $AR(p)$  tem o forma:

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

Ou em forma vetorial:

$$\boldsymbol{\xi}_t = \mathbf{F} \boldsymbol{\xi}_{t-1} + \mathbf{v}_t,$$

Avaliando a fórmula 10.2.19 para um processo escalar temos:

$$\text{vec} \begin{bmatrix} \gamma_0 & \gamma_1 & \cdots & \gamma_{p-1} \\ \gamma_1 & \gamma_0 & \cdots & \gamma_{p-2} \\ \vdots & \vdots & \vdots & \vdots \\ \gamma_{p-1} & \gamma_{p-2} & \cdots & \gamma_0 \end{bmatrix} = [\mathbf{I}_{p^2} - \mathcal{A}]^{-1} \text{vec}(\mathbf{Q}).$$

Com

$$\mathcal{A} \equiv \mathbf{F}_{(p \times p)} \otimes \mathbf{F}_{(p \times p)}$$

Temos ainda que  $\mathbf{Q}$  para um processo escalar se torna:

$$\begin{aligned}\mathbf{Q} &= E[\mathbf{v}\mathbf{v}'] = E \left\{ \begin{bmatrix} \varepsilon_t \\ 0 \\ \vdots \\ 0 \end{bmatrix} \begin{bmatrix} \varepsilon_t & 0 & \cdots & 0 \end{bmatrix} \right\} \\ &= E \begin{bmatrix} \varepsilon_t^2 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix} = \sigma^2 \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix}\end{aligned}$$

Realizando a operação vec nos dois lados da equação 10.2.19 para o processo escalar:

$$\begin{bmatrix} \gamma_0 \\ \gamma_1 \\ \vdots \\ \gamma_{p-1} \\ \gamma_1 \\ \gamma_0 \\ \vdots \\ \gamma_{p-2} \\ \vdots \\ \gamma_{p-1} \\ \gamma_{p-2} \\ \vdots \\ \gamma_0 \end{bmatrix} = [\mathbf{I}_{p^2} - \mathcal{A}]^{-1} \sigma^2 \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \\ 0 \\ 0 \\ \vdots \\ 0 \\ \vdots \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

dados que  $[\mathbf{I}_{p^2} - \mathcal{A}]^{-1}$  é uma matriz  $p^2 \times p^2$  e o vetor coluna do lado direito tem dimensão  $p^2 \times 1$ , o produto dos dois termos pode ser feito da seguinte forma. Deixe que  $[\mathbf{I}_{p^2} - \mathcal{A}]^{-1}$  seja igual a uma matriz  $\mathbf{H}$  e que ela seja particionada em  $p^2$  vetores coluna  $\mathbf{h}_j$  de dimensão  $p^2 \times 1$  com  $j = 1, 2, \dots, p^2$ .

$$\mathbf{H} = [\mathbf{h}_1 \quad \mathbf{h}_2 \quad \cdots \quad \mathbf{h}_{p^2}]$$

Então o produto fica um vetor coluna de dimensão  $p^2 \times 1$ :

$$[\mathbf{h}_1 \quad \mathbf{h}_2 \quad \cdots \quad \mathbf{h}_{p^2}] \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}_{(p^2 \times 1)} = [\mathbf{h}_1(1) + \mathbf{h}_2(0) + \cdots + \mathbf{h}_{p^2}(0)]_{(p^2 \times 1)} = [\mathbf{h}_1]_{(p^2 \times 1)}$$

Com isso os  $p$  primeiros termos do lado esquerdo do processo escalar empilhado é o vetor coluna

$$\begin{bmatrix} \gamma_0 \\ \gamma_1 \\ \gamma_2 \\ \vdots \\ \gamma_{p-1} \end{bmatrix}$$

e os  $p$  primeiros termos do lado direito desta mesma equação é um vetor composto pelos  $p$  primeiros elementos do vetor

$$\sigma^2 [\mathbf{h}_1]_{(p^2 \times 1)},$$

que é equivalente aos  $p$  primeiros elementos da primeira coluna de

$$\sigma^2 \mathbf{H} \equiv \sigma^2 [\mathbf{I}_{p^2} - \mathcal{A}]^{-1} \quad \blacksquare$$

10.2 a) Sendo  $\mathbf{y} = (X_t, Y_t)'$ :

$$\mathbf{\Gamma}_k = E[(\mathbf{y}_t - \boldsymbol{\mu})(\mathbf{y}_{t-k} - \boldsymbol{\mu})']$$

Dados que no exercício  $\mu_X = \mu_Y = 0$ :

$$\begin{aligned} \mathbf{\Gamma}_k &= E[(\mathbf{y}_t)(\mathbf{y}_{t-k})'] \\ &= E \left\{ \begin{bmatrix} X_t \\ Y_t \end{bmatrix} \begin{bmatrix} X_{t-k} & Y_{t-k} \end{bmatrix} \right\} \\ &= E \begin{bmatrix} X_t X_{t-k} & X_t Y_{t-k} \\ Y_t X_{t-k} & Y_t Y_{t-k} \end{bmatrix} \end{aligned}$$

$$\begin{aligned} \mathbf{\Gamma}_0 &= E \begin{bmatrix} X_t X_t & X_t Y_t \\ Y_t X_t & Y_t Y_t \end{bmatrix} \\ &= E \begin{bmatrix} (\varepsilon_t + \theta \varepsilon_{t-1})(\varepsilon_t + \theta \varepsilon_{t-1}) & (\varepsilon_t + \theta \varepsilon_{t-1})(h_1 X_{t-1} + u_t) \\ (h_1 X_{t-1} + u_t)(\varepsilon_t + \theta \varepsilon_{t-1}) & (h_1 X_{t-1} + u_t)(h_1 X_{t-1} + u_t) \end{bmatrix} \\ &= E \begin{bmatrix} (\varepsilon_t + \theta \varepsilon_{t-1})(\varepsilon_t + \theta \varepsilon_{t-1}) & (\varepsilon_t + \theta \varepsilon_{t-1})(h_1(\varepsilon_{t-1} + \theta \varepsilon_{t-2}) + u_t) \\ (h_1(\varepsilon_{t-1} + \theta \varepsilon_{t-2}) + u_t)(\varepsilon_t + \theta \varepsilon_{t-1}) & (h_1(\varepsilon_{t-1} + \theta \varepsilon_{t-2}) + u_t)(h_1(\varepsilon_{t-1} + \theta \varepsilon_{t-2}) + u_t) \end{bmatrix} \\ &= \begin{bmatrix} \sigma_\varepsilon^2[1 + \theta^2] & h_1 \theta \sigma_\varepsilon^2 \\ h_1 \theta \sigma_\varepsilon^2 & \sigma_\varepsilon^2 h_1^2[1 + \theta^2] + \sigma_u^2 \end{bmatrix} \end{aligned}$$

$$\begin{aligned} \mathbf{\Gamma}_1 &= E \begin{bmatrix} X_t X_{t-1} & X_t Y_{t-1} \\ Y_t X_{t-1} & Y_t Y_{t-1} \end{bmatrix} \\ &= E \begin{bmatrix} (\varepsilon_t + \theta \varepsilon_{t-1})(\varepsilon_{t-1} + \theta \varepsilon_{t-2}) & (\varepsilon_t + \theta \varepsilon_{t-1})(h_1 X_{t-2} + u_{t-1}) \\ (h_1 X_{t-1} + u_t)(\varepsilon_{t-1} + \theta \varepsilon_{t-2}) & (h_1 X_{t-1} + u_t)(h_1 X_{t-2} + u_{t-1}) \end{bmatrix} \\ &= E \begin{bmatrix} (\varepsilon_t + \theta \varepsilon_{t-1})(\varepsilon_{t-1} + \theta \varepsilon_{t-2}) & (\varepsilon_t + \theta \varepsilon_{t-1})(h_1(\varepsilon_{t-2} + \theta \varepsilon_{t-3}) + u_{t-1}) \\ (h_1(\varepsilon_{t-1} + \theta \varepsilon_{t-2}) + u_t)(\varepsilon_{t-1} + \theta \varepsilon_{t-2}) & (h_1(\varepsilon_{t-1} + \theta \varepsilon_{t-2}) + u_t)(h_1(\varepsilon_{t-2} + \theta \varepsilon_{t-3}) + u_{t-1}) \end{bmatrix} \\ &= \begin{bmatrix} \theta \sigma_\varepsilon^2 & 0 \\ h_1 \sigma_\varepsilon^2[1 + \theta^2] & h_1^2 \theta \sigma_\varepsilon^2 \end{bmatrix} \end{aligned}$$

$$\begin{aligned} \mathbf{\Gamma}_2 &= E \begin{bmatrix} X_t X_{t-2} & X_t Y_{t-2} \\ Y_t X_{t-2} & Y_t Y_{t-2} \end{bmatrix} \\ &= E \begin{bmatrix} (\varepsilon_t + \theta \varepsilon_{t-1})(\varepsilon_{t-2} + \theta \varepsilon_{t-3}) & (\varepsilon_t + \theta \varepsilon_{t-1})(h_1 X_{t-3} + u_{t-2}) \\ (h_1 X_{t-1} + u_t)(\varepsilon_{t-2} + \theta \varepsilon_{t-3}) & (h_1 X_{t-1} + u_t)(h_1 X_{t-3} + u_{t-2}) \end{bmatrix} \\ &= E \begin{bmatrix} (\varepsilon_t + \theta \varepsilon_{t-1})(\varepsilon_{t-2} + \theta \varepsilon_{t-3}) & (\varepsilon_t + \theta \varepsilon_{t-1})(h_1(\varepsilon_{t-3} + \theta \varepsilon_{t-4}) + u_{t-2}) \\ (h_1(\varepsilon_{t-1} + \theta \varepsilon_{t-2}) + u_t)(\varepsilon_{t-2} + \theta \varepsilon_{t-3}) & (h_1(\varepsilon_{t-1} + \theta \varepsilon_{t-2}) + u_t)(h_1(\varepsilon_{t-3} + \theta \varepsilon_{t-4}) + u_{t-2}) \end{bmatrix} \\ &= \begin{bmatrix} 0 & 0 \\ h_1 \theta \sigma_\varepsilon^2 & 0 \end{bmatrix} \end{aligned}$$

Temos ainda que  $\mathbf{\Gamma}_j = \mathbf{0}$  para  $j \geq 3$ .  $\blacksquare$

b) Equação 10.4.3:

$$\mathbf{s}_y(\omega) = (2\pi)^{-1} \mathbf{G}_y(e^{-i\omega}) = (2\pi)^{-1} \sum_{k=-\infty}^{\infty} \mathbf{\Gamma}_k e^{-i\omega k}.$$

Neste caso  $k = -1, 0, 1$ . Lembrando que  $\mathbf{\Gamma}_{-k} = \mathbf{\Gamma}'_k$ :

$$\mathbf{s}_y(\omega) = (2\pi)^{-1} \sum_{k=-1}^1 \mathbf{\Gamma}_k e^{-i\omega k}$$

Que de acordo com 10.4.11 fica:

$$\mathbf{s}_y(\omega) = \frac{1}{2\pi} \begin{bmatrix} \sum_{k=-2}^2 \gamma_{XX}^{(k)} \cos(\omega k) & \sum_{k=-2}^2 \gamma_{XY}^{(k)} \{\cos(\omega k) - i \sin(\omega k)\} \\ \sum_{k=-2}^2 \gamma_{YX}^{(k)} \{\cos(\omega k) - i \sin(\omega k)\} & \sum_{k=-2}^2 \gamma_{YY}^{(k)} \cos(\omega k) \end{bmatrix}$$

Analisando cada termo separadamente, lembrando que  $\cos(0) = 1$  e  $\cos(\omega) = \cos(-\omega)$ :

$$\begin{aligned} \mathbf{s}_y(\omega)^{11} &= \sum_{k=-2}^2 \gamma_{XX}^{(k)} \cos(\omega k) = \theta \sigma_\varepsilon^2 \cos(-\omega) + \sigma_\varepsilon^2 [1 + \theta^2] + \theta \sigma_\varepsilon^2 \cos(\omega) \\ &= \sigma_\varepsilon^2 [1 + 2\theta \cos(\omega) + \theta^2] \end{aligned}$$

$$\begin{aligned} \mathbf{s}_y(\omega)^{22} &= \sum_{k=-2}^2 \gamma_{YY}^{(k)} \cos(\omega k) = h_1^2 \theta \sigma_\varepsilon^2 \cos(-\omega) + \sigma_\varepsilon^2 h_1^2 [1 + \theta^2] \\ &\quad + \sigma_u^2 + h_1^2 \theta \sigma_\varepsilon^2 \cos(\omega) \\ &= \sigma_\varepsilon^2 [h_1^2 [1 + \theta^2] + h_1^2 2\theta \cos(\omega)] + \sigma_u^2 \end{aligned}$$

$$\mathbf{s}_y(\omega)^{12} = \sum_{k=-2}^2 \gamma_{XY}^{(k)} e^{-i\omega k} = h_1 \theta \sigma_\varepsilon^2 e^{i2\omega} + h_1 \sigma_\varepsilon^2 [1 + \theta^2] e^{i\omega} + h_1 \theta \sigma_\varepsilon^2$$

$$\mathbf{s}_y(\omega)^{21} = \sum_{k=-2}^2 \gamma_{YX}^{(k)} e^{-i\omega k} = h_1 \theta \sigma_\varepsilon^2 + h_1 \sigma_\varepsilon^2 [1 + \theta^2] e^{-i\omega} + h_1 \theta \sigma_\varepsilon^2 e^{-i2\omega}$$

O *spectrum* populacional fica:

$$\mathbf{s}_y(\omega) = \frac{1}{2\pi} \begin{bmatrix} \mathbf{s}_y(\omega)^{11} & \mathbf{s}_y(\omega)^{12} \\ \mathbf{s}_y(\omega)^{21} & \mathbf{s}_y(\omega)^{22} \end{bmatrix}$$

O *cospectrum* entre  $X$  e  $Y$  é:

$$c_{XY}(\omega) = (2\pi)^{-1} h_1 \sigma_\varepsilon^2 (\theta \cos(2\omega) + [1 + \theta^2] \cos(\omega) + \theta)$$

E o *quadrature spectrum* entre  $X$  e  $Y$  é:

$$q_{XY}(\omega) = -(2\pi)^{-1} h_1 \sigma_\varepsilon^2 (\theta \sin(2\omega) + [1 + \theta^2] \sin(\omega))$$

c) Equação 10.4.45:

$$\begin{aligned} \mathbf{s}_y(\omega) &= \begin{bmatrix} 1 & 0 \\ h(e^{-i\omega}) & 1 \end{bmatrix} \begin{bmatrix} s_{XX}(\omega) & 0 \\ 0 & s_{UU}(\omega) \end{bmatrix} \begin{bmatrix} 1 & h(e^{i\omega}) \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} s_{XX}(\omega) & s_{XX}(\omega)h(e^{i\omega}) \\ h(e^{-i\omega})s_{XX}(\omega) & h(e^{-i\omega})s_{XX}(\omega)h(e^{i\omega}) + s_{UU}(\omega) \end{bmatrix}, \end{aligned}$$

onde

$$h(e^{-i\omega}) = \sum_{k=-\infty}^{\infty} h_k e^{-i\omega k}$$

Que neste caso  $h(e^{-i\omega}) = h_1 e^{-i\omega}$  pois  $h_k = 0$  para  $k \neq 1$ .

$$\begin{aligned} s_{XX}(\omega) &= (2\pi)^{-1} \sum_{k=-\infty}^{\infty} \gamma_{XX}^{(k)} e^{-i\omega k} \\ &= (2\pi)^{-1} \left[ \sigma_\varepsilon^2 \theta e^{-i\omega} + \sigma_\varepsilon^2 [1 + \theta^2] + \sigma_\varepsilon^2 \theta e^{i\omega} \right] \\ &= (2\pi)^{-1} \sigma_\varepsilon^2 \left[ 1 + 2\theta \cos(\omega) + \theta^2 \right] \end{aligned}$$

$$s_{UU}(\omega) = (2\pi)^{-1} \sigma_u^2$$

$$\begin{aligned} s_{XX}(\omega)[h_1 e^{-i\omega}] &= (2\pi)^{-1} \left[ \sigma_\varepsilon^2 \theta e^{-i\omega} + \sigma_\varepsilon^2 [1 + \theta^2] + \sigma_\varepsilon^2 \theta e^{i\omega} \right] [h_1 e^{-i\omega}] \\ &= (2\pi)^{-1} h_1 \sigma_\varepsilon^2 \left[ \theta e^{-i2\omega} + [1 + \theta^2] e^{-i\omega} + \theta \right] \\ &= (2\pi)^{-1} h_1 \sigma_\varepsilon^2 \left[ \theta \{ \cos(2\omega) - i \operatorname{sen}(2\omega) \} + [1 + \theta^2] \{ \cos(\omega) - i \operatorname{sen}(\omega) \} + \theta \right] \end{aligned}$$

$$\begin{aligned} s_{XX}(\omega)h(e^{i\omega}) &= (2\pi)^{-1} \left[ \sigma_\varepsilon^2 \theta e^{-i\omega} + \sigma_\varepsilon^2 [1 + \theta^2] + \sigma_\varepsilon^2 \theta e^{i\omega} \right] [h_1 e^{i\omega}] \\ &= (2\pi)^{-1} h_1 \sigma_\varepsilon^2 \left[ \theta + [1 + \theta^2] e^{i\omega} + \theta e^{i2\omega} \right] \\ &= (2\pi)^{-1} h_1 \sigma_\varepsilon^2 \left[ \theta + [1 + \theta^2] \{ \cos(\omega) + i \operatorname{sen}(\omega) \} + \theta \{ \cos(2\omega) + i \operatorname{sen}(2\omega) \} \right] \end{aligned}$$

$$\begin{aligned} h(e^{-i\omega})s_{XX}(\omega)h(e^{i\omega}) + s_{UU}(\omega) &= (2\pi)^{-1} h_1 \sigma_\varepsilon^2 \left[ \theta e^{-i2\omega} + [1 + \theta^2] e^{-i\omega} + \theta \right] [h_1 e^{i\omega}] + s_{UU} \\ &= (2\pi)^{-1} h_1^2 \sigma_\varepsilon^2 \left[ \theta e^{-i\omega} + [1 + \theta^2] + \theta e^{i\omega} \right] + (2\pi)^{-1} \sigma_u^2 \\ &= (2\pi)^{-1} h_1^2 \sigma_\varepsilon^2 \left[ 2\theta \{ \cos(\omega) \} + [1 + \theta^2] \right] + (2\pi)^{-1} \sigma_u^2 \end{aligned}$$

d) Equação 10.4.49:

$$h_k = (2\pi)^{-1} \int_{-\pi}^{\pi} \frac{s_{YX}(\omega)}{s_{XX}(\omega)} e^{i\omega k} d\omega.$$

Quando  $k = 1$ :

$$\begin{aligned}
 h_1 &= (2\pi)^{-1} \int_{-\pi}^{\pi} \frac{(2\pi)^{-1} [h_1 \theta \sigma_{\varepsilon}^2 + h_1 \sigma_{\varepsilon}^2 [1 + \theta^2] e^{-i\omega} + h_1 \theta \sigma_{\varepsilon}^2 e^{-i2\omega}]}{(2\pi)^{-1} \sigma_{\varepsilon}^2 [1 + 2\theta \cos(\omega) + \theta^2]} e^{i\omega} d\omega \\
 &= (2\pi)^{-1} \int_{-\pi}^{\pi} \frac{[h_1 \theta \sigma_{\varepsilon}^2 e^{i\omega} + h_1 \sigma_{\varepsilon}^2 [1 + \theta^2] + h_1 \theta \sigma_{\varepsilon}^2 e^{-i\omega}]}{\sigma_{\varepsilon}^2 [1 + 2\theta \cos(\omega) + \theta^2]} d\omega \\
 &= (2\pi)^{-1} \int_{-\pi}^{\pi} \frac{\left( h_1 \sigma_{\varepsilon}^2 [\theta e^{i\omega} + [1 + \theta^2] + \theta e^{-i\omega}] \right)}{\sigma_{\varepsilon}^2 [1 + 2\theta \cos(\omega) + \theta^2]} d\omega \\
 &= (2\pi)^{-1} \int_{-\pi}^{\pi} \frac{\left( h_1 \sigma_{\varepsilon}^2 [1 + 2\theta \cos(\omega) + \theta^2] \right)}{\sigma_{\varepsilon}^2 [1 + 2\theta \cos(\omega) + \theta^2]} d\omega \\
 &= (2\pi)^{-1} \int_{-\pi}^{\pi} h_1 d\omega = h_1
 \end{aligned}$$

Quando  $k \neq 1$ :

$$\begin{aligned}
 h_k &= (2\pi)^{-1} \int_{-\pi}^{\pi} h_1 e^{-i\omega} e^{i\omega k} d\omega \\
 &= (2\pi)^{-1} \int_{-\pi}^{\pi} h_1 e^{(k-1)i\omega} d\omega \\
 &= (2\pi)^{-1} \int_{-\pi}^{\pi} h_1 \cos([k-1]\omega) d\omega + i(2\pi)^{-1} \int_{-\pi}^{\pi} h_1 \sin([k-1]\omega) d\omega \\
 &= ([k-1]2\pi)^{-1} h_1 \left[ \sin([k-1]\omega) \right]_{-\pi}^{\pi} - i([k-1]2\pi)^{-1} h_1 \left[ \cos([k-1]\omega) \right]_{-\pi}^{\pi} \\
 &= 0 \quad \blacksquare
 \end{aligned}$$